


Roteiro de aulas: Correlação de *linear*

Disciplina: Probabilidade e Estatística

Professor: André Oliveira

08 de dezembro de 2025



Correlação de *Pearson*

A correlação de *Pearson* é uma técnica estatística para medir o quanto duas variáveis **quantitativas** estão **linearmente** relacionadas. Muitas vezes experimentos são conduzidos para investigar se existe **relação linear** entre duas variáveis quantitativas, por exemplo, a dose de uma droga e a reação, peso e altura de humanos, idade da vaca e a produção de leite, etc. É um coeficiente adimensional, ou seja não tem unidade de medida. Em muitos estudos o objetivo é identificar a forma de **relacionamento entre variáveis**. O que se procura é mensurar o quanto variáveis diferentes são relacionadas entre si e conseguir um modelo estatístico que explique de que forma variáveis se relacionam. Existem outros tipos de correlação: Correlação de **Spearman** e Correlação de **Kendall**. As duas variáveis quando medidas estão sujeitas a erros experimentais, isto é, erros de natureza aleatória e inerentes ao experimento. Por exemplo, produção de leite e produção de gordura medidas em vacas em lactação, peso do pai e peso do filho, comprimento e a largura do crânio de animais, etc. O coeficiente de **correlação** mede a intensidade da relação entre duas variáveis. O coeficiente de correlação define apenas o **sentido** da variação **conjunta** das variáveis e a **correlação** não implica **causalidade**. A ausência de **correlação linear** não indica ausência de relação entre as variáveis.

Uma correlação **positiva** indica que quando os valores de uma variável **independente** X aumenta os valores da variável **dependente** Y também aumentam. Uma correlação **negativa** indica que quando os valores de uma variável **independente** X aumenta e os valores da variável **dependente** Y diminui.

O coeficiente de **correlação de Pearson**, denotado por ρ_{xy} , é um índice adimensional que varia no intervalo $[-1, 1]$ e quantifica a intensidade e a direção da associação linear entre duas variáveis. Sua definição populacional é dado por

$$\rho_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}},$$

em que SPD_{xy} representa o somatório dos produtos das diferenças em relação às médias e SQD_x e SQD_y correspondem aos somatórios dos quadrados das diferenças das variáveis X e Y , respectivamente.

O coeficiente de **correlação amostral** de **Pearson**, denotado por $\hat{\rho}_{xy}$, é dado por

$$\hat{\rho}_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}}$$

em que,

$$SPD_{xy} = \sum_{i=1}^n X_i \cdot Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \cdot \left(\sum_{i=1}^n Y_i\right)}{n}, \quad SQD_y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n}, \quad SQD_x = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n}$$

Visualmente uma correlação pode ser avaliada como segue por diagramas de **dispersão** abaixo.




Figura 1: Ausência de relação linear entre as variáveis X e Y




Figura 2: Pares possibilidades de relação linear entre as variáveis X e Y

Exemplo

As produções médias de leite em kg (Y) de um grupo de vacas tratadas com diferentes níveis de proteína em (%) na ração (X) são apresentadas na Tabela 01 abaixo.

Tabela 01: Dados experimentais da quantidade de proteína na alimentação e produção média de leite.

Níveis de proteína (X)	Produção média (Y)
10	11,80
12	12,00
14	12,10
16	13,20
18	14,10
20	14,40
22	15,60
24	16,00
26	16,40
28	17,00

Plotando os pares em um **diagrama de dispersão** nos mostra que há uma associação linear.




Figura 3: Diagrama de dispersão entre as variáveis percentual de proteína na ração (X) e produção média de leite em kg (Y).

O **coeficiente de correlação amostral de Pearson** é $\hat{\rho}_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}}$

$$SPD_{xy} = \sum_{i=1}^n X_i \cdot Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \cdot \left(\sum_{i=1}^n Y_i\right)}{n} = 2814,00 - \frac{190,00 \cdot 142,60}{10} = 104,60$$

$$SQD_y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n} = 2067,38 - \frac{(142,60)^2}{10} = 33,90$$

$$SQD_x = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} = 3940,00 - \frac{(190,00)^2}{10} = 330,00$$

$$\hat{\rho}_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}} = \frac{104,6}{\sqrt{330,00 \cdot 33,90}} = 0,9889$$

Interpretação

A produção média de leite em kg (Y) e níveis de proteína em (%) inseridos na ração (X) tem uma correlação (associação) forte e positiva (0,9889). Os valores da variável X **aumentam** e os valores da variável Y também **aumentam**. Este coeficiente de correlação define o **sentido** da variação conjunta das variáveis.


Exercícios

- 1) A renda mensal média de vendas de refeições (Y), assim como os gastos mensais com propaganda (X), foram registradas para 30 restaurantes. Um analista de vendas gostaria de saber se há associação linear entre as vendas e os gastos com propagandas por meio da correlação de *Pearson*.
 - a) Plote o diagrama de dispersão;
 - b) Otenha a estimativa do coeficiente de correlação de *Pearson* para estes dados e interprete.

Tabela 02: Vendas de refeições em função do gasto com propaganda

Gasto mensal com propaganda (X)	Vendas de refeições (Y)
3	81
3	73
3	72
5	91
5	99
5	97
9	127
9	114
9	116
9	123
9	131
12	141
12	151
12	147
12	131
12	145
12	147
15	179
15	166
15	181
15	178
15	185
15	156
17	176
17	189
17	192
19	203
19	193
19	219
19	214

Diagrama de dispersão:



Dados auxiliares para solução:

$$\sum_{i=1}^{30} X_i = 358,00; \sum_{i=1}^{30} Y_i = 4417,00; \sum_{i=1}^{30} Y_i^2 = 701901,00; \sum_{i=1}^{30} X_i^2 = 5032,00; \sum_{i=1}^{30} (X_i \cdot Y_i) = 58851,00$$

$$SPD_{xy} = \sum_{i=1}^{30} X_i \cdot Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \cdot \left(\sum_{i=1}^n Y_i\right)}{n} = 58851,00 - \frac{(358,00) \cdot (4417,00)}{30} = 6141,47$$

$$SQD_y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n} = 701901,00 - \frac{(4417,00)^2}{30} = 51571,37$$

$$SQD_x = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} = 5032,00 - \frac{(358,00)^2}{30} = 759,87$$

$$\hat{\rho}_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}} = \frac{6141,47}{\sqrt{(759,87) \cdot (51571,37)}} = 0,9810$$

Interpretação

A estimativa do coeficiente de correlação de *Pearson* foi $\hat{\rho}_{xy} = 0,9810$, evidenciando uma associação linear forte e **positiva** entre as vendas e os investimentos em propaganda.


- 2) Os dados da Tabela 03 indicam o valor do aluguel (Y) e a idade do imóvel (X).

Tabela 03: Dados referente a preços de alugueis (salário mínimo) e a idade dos imóveis (anos).

Idade do imóvel (X)	Valor do aluguel (Y)
10	4
13	3
5	6
7	5
20	2

- Plote o diagrama de dispersão;
- Otenha a estimativa do coeficiente de correlação de **Pearson** para estes dados e interprete.

Diagrama de dispersão:



Dados auxiliares para solução:

$$\sum_{i=1}^n X_i = 55,00; \sum_{i=1}^n Y_i = 20,00; \sum_{i=1}^n Y_i^2 = 90,00; \sum_{i=1}^n X_i^2 = 743,00; \sum_{i=1}^n (X_i \cdot Y_i) = 184,00$$

$$SPD_{xy} = \sum_{i=1}^n X_i \cdot Y_i - \frac{\left(\sum_{i=1}^n X_i\right) \cdot \left(\sum_{i=1}^n Y_i\right)}{n} = 184,00 - \frac{(55,00) \cdot (20,00)}{5} = -36,00$$

$$SQD_y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n} = 90,00 - \frac{(20,00)^2}{5} = 10,00$$

$$SQD_x = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} = 743,00 - \frac{(55,00)^2}{5} = 138,00$$

$$\hat{\rho}_{xy} = \frac{SPD_{xy}}{\sqrt{SQD_x \cdot SQD_y}} = \frac{-36,00}{\sqrt{(138,00) \cdot (10,00)}} = -0,9691$$

Interpretação

A estimativa do coeficiente de correlação de **Pearson** foi $\hat{\rho}_{xy} = -0,9691$, evidenciando uma associação linear forte e **negativa** entre valor do aluguel (Y) e a idade do imóvel (X).