


Roteiro de aulas: *Regressão Linear simples*

Disciplina: *Probabilidade e Estatística*

Professor: André Oliveira

15 de dezembro de 2025



Regressão Linear simples

A regressão linear busca estabelecer uma relação funcional entre uma variável dependente (variável resposta) e uma variável independente (variável regressora ou variável explicativa) modelando o valor médio esperado da variável resposta. Em geral, se dá para a técnica de correlação uma importância menor do que a técnica da **regressão**. Entretanto se duas variáveis estão correlacionadas, é muito mais útil estudar as posições de uma ou de ambas por meio de curvas de regressão, as quais permitem, por exemplo, a **predição** de uma variável em função de outra, do que estudá-las por meio de apenas o coeficiente de correlação. A análise de correlação avalia o grau de associação entre variáveis e a análise de **regressão** procura verificar a existência de uma relação funcional entre essas variáveis com objetivo de **predição**. É importante salientar que o coeficiente de correlação define apenas o sentido da variação conjunta das variáveis, ou seja, como duas variáveis tendem variar simultaneamente em uma direção ou em direções contrárias, onde os dados provavelmente indicariam uma correlação, positiva ou negativa, alta, não implicaria necessariamente na presença de uma relação de causa e efeito entre elas.

O modelo de **regressão linear** pressupõe linearidade na relação entre as variáveis, **normalidade** dos resíduos, **homocedasticidade** (constância da variância dos resíduos) e ausência de observações atípicas influentes, pois estas podem induzir heterocedasticidade e comprometer a validade das inferências.

Considerando o modelo de regressão linear simples $Y_i = \beta_0 + \beta_1 X_i + e_i$ as estimativas dos coeficientes β_0 e β_1 podem ser obtidas pelo método de mínimos quadrados (MMQ) que minimiza a soma de quadrado do erros do modelo. Os estimadores de mínimos quadrados para o modelo de **regressão linear simples** é a solução do sistema de equações normais.

$$\begin{cases} \sum_{i=1}^n Y_i = n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i \\ \sum_{i=1}^n Y_i X_i = \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \end{cases}$$

Assim a solução do sistema acima é $\hat{\beta}_1 = \frac{SPD_{xy}}{SQD_x}$ e $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \cdot \bar{X}$, em que $\bar{Y}$ é a média da variável dependente e $\bar{X}$ é a média da variável independente.

Uma vez obtidas estas estimativas, escreve-se a equação estimada (modelo ajustado) $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i$

Coeficiente de determinação (R^2) é uma das métricas de avaliação do modelo de regressão proposto. Este coeficiente tem variação de [0% a 100%] e avalia se o modelo proposto é adequado ou não para descrever o valor médio da variável dependente em função dos valores da variável independente.

O coeficiente de determinação é dado por $R^2 = \frac{\hat{\beta}_1 \cdot SPD_{xy}}{SQD_y}$, $R^2 = \frac{SPD_{xy}^2}{(SQD_y) \cdot (SQD_x)}$ ou simplesmente por $R^2 = \rho_{xy}^2$. Em que

$$SPD_{xy} = \sum_{i=1}^n (X_i \cdot Y_i) - \frac{\left(\sum_{i=1}^n X_i\right) \cdot \left(\sum_{i=1}^n Y_i\right)}{n}, \quad SQD_y = \sum_{i=1}^n Y_i^2 - \frac{\left(\sum_{i=1}^n Y_i\right)^2}{n},$$

$$SQD_x = \sum_{i=1}^n X_i^2 - \frac{\left(\sum_{i=1}^n X_i\right)^2}{n} \quad e \quad \rho_{xy} = \frac{SPD_{xy}}{\sqrt{(SQD_x) \cdot (SQD_y)}}.$$

O coeficiente R^2 indica a proporção (%) da variação total de Y que é explicada pelo modelo de regressão **proposto**, ou o quanto da variação na variável dependente (variável resposta) Y está sendo explicada pela variável independente (preditora/explicativa) X .

Exemplo

Um analista de vendas gostaria de encontrar a relação entre a renda mensal média de vendas de refeições (Y) e o investimento mensal com propaganda (X). Os dados foram observados em 7 restaurantes de mesmo padrão.

Tabela 1: Dados de vendas e investimento mensal com propaganda

Gasto	Vendas
3	75
5	105
9	120
12	160
15	174
17	179
19	207

Ajustar o modelo regressão linear $Y_i = \beta_0 + \beta_1 X_i + e_i$.


- Construa um diagrama de dispersão das variáveis X e Y .
- Obtenha a equação estimada;
- Obtenha o coeficiente de determinação (R^2);
- Interprete os parâmetros da equação estimada;
- Interprete o coeficiente de determinação (R^2);
- Obtenha o valor médio estimado (esperado) para um restaurante que fizer um investimento de 14.

Dados auxiliares:

$$\sum_{i=1}^7 X_i = 80,00; \sum_{i=1}^7 X_i^2 = 1134,00; \sum_{i=1}^7 Y_i = 1020,00; \sum_{i=1}^7 Y_i^2 = 161816,00; \sum_{i=1}^7 (X_i \cdot Y_i) = 13336,00$$

Resolução

- Construa um diagrama de dispersão das variáveis X e Y .



b) Obtenha a equação estimada.

$$\hat{\beta}_1 = \frac{SPD_{xy}}{SQD_x} = \frac{1678,86}{219,71} = 7,64; \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \cdot \bar{X} = 145,71 - (7,64 \times 11,43) = 58,38$$

Assim a equação estimada é $\hat{Y} = 58,38 + 7,64.X$.

c) Obtenha o coeficiente de determinação (R^2).

$$R^2 = \frac{\hat{\beta}_1 \cdot SPD_{xy}}{SQD_y} = \frac{7,64 \times 1678,86}{13187,43} = 0,9726$$

d) Interprete os parâmetros da equação estimada.

O valor de $\hat{\beta}_0 = 58,38$ é o valor médio de vendas esperado para a empresa (restaurante) que não investe em propaganda e $\hat{\beta}_1 = 7,64$ é o incremento médio das vendas (Y) para **cada unidade** a mais de investimento em (X).

e) Interprete o coeficiente de determinação (R^2).

Dessa forma, aproximadamente 97,26% da variabilidade das vendas (Y) pode ser explicada pelo investimento em propaganda (X), segundo o modelo de regressão ajustado (modelo proposto).

f) Obtenha o valor médio estimado (esperado) para um restaurante que fizer um investimento de 14.

A equação estimada é $\hat{Y} = 58,38 + 7,64.X$ assim para $X = 14$ tem-se que:

$$\hat{Y}_{(14)} = 58,38 + 7,64 \times 14 = 165,34$$




Figura 1: Diagrama de dispersão dos dados com resumo do modelo linear simples ajustado (modelo proposto).

- 2) Os dados da Tabela abaixo indicam o valor do aluguel (Y) e a idade do imóvel (X).

Tabela 2: Dados referentes a preços de aluguéis (salário mínimo) e a idade dos imóveis (anos).


Idade do imóvel (X)	Valor do aluguel (Y)
10	4
13	3
5	6
7	5
20	2

Ajuste o modelo regressão linear $Y_i = \beta_0 + \beta_1 X_i + e_i$.

- Construa um diagrama de dispersão das variáveis X e Y .
- Obtenha a equação estimada;
- Obtenha o coeficiente de determinação (R^2);
- Interprete os parâmetros da equação estimada;
- Interprete o coeficiente de determinação (R^2);
- Obtenha o valor médio estimado (esperado) do aluguel de um imóvel com idade de 8 anos.

Solução

- a) Construa um diagrama de dispersão das variáveis X e Y .



- b) Obtenha a equação estimada;

$$\hat{\beta}_1 = \frac{SPD_{xy}}{SQD_x} = \frac{-36,00}{138,00} = -0,2609; \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \cdot \bar{X} = 4,00 - (-0,2609 \times 11,00) = 6,869$$

Assim a equação estimada é $\hat{Y} = 6,870 - 0,2609 \cdot X$.

- c) Obtenha o coeficiente de determinação (R^2);

$$R^2 = \frac{\hat{\beta}_1 \cdot SPD_{xy}}{SQD_y} = \frac{(-0,2609) \times (-36,00)}{10,00} = 0,9392$$

- d) Interprete os parâmetros da equação estimada;

O valor de $\hat{\beta}_0 = 6,870$ é o valor médio esperado do aluguel (Y) para um imóvel novo e $\hat{\beta}_1 = -0,2609$ é o decréscimo médio do valor do aluguel (Y) para **cada ano** a mais na idade do imóvel (X).

- e) Interprete o coeficiente de determinação (R^2);

Dessa forma, aproximadamente 93,92% da variabilidade do valor do aluguel (Y) pode ser explicada pela idade do imóvel (X), segundo o modelo de regressão ajustado (modelo proposto).

- f) Obtenha o valor médio estimado (esperado) do aluguel um imóvel com idade de 8 anos.

A equação estimada é $\hat{Y} = 6,870 - 0,2609 \cdot X$. Assim $\hat{Y}_{(8)} = 6,870 - 0,2609 \times 8,00 = 4,78$ salários mínimos.




Figura 2: Diagrama de dispersão dos dados com resumo do modelo linear simples ajustado (modelo proposto).